Bayesian Optimization

Sections 2.5 – 2.9

choi yoonseo

January 29, 2026

Outline

1. 2.5 Continuity
2. 2.6 Differentiability
3. 2.7 Existence and Uniqueness of Global Maxima
4. 2.8 Non-Gaussian Observations and Constraints

Continuity in Mean Square

- **Definition**

$$\lim_{x \to x'} \mathbb{E}\left[|f(x) - f(x')|^2\right] = 0$$

- Suppose $f : \mathcal{X} \to \mathbb{R}$ has distribution $\mathcal{GP}(f; \mu, K)$. Let $f(x) = \phi(x)$ and $f(x') = \phi'$. Then,

$$p(\phi - \phi' | x, x') = \mathcal{N}(\phi - \phi'; m, s^2) \quad (\because \text{Affine transformation, A.9})$$

  - $m = \mu(x) - \mu(x')$
  - $s^2 = K(x, x) - 2K(x, x') + K(x', x')$

- **결론**: 만약 μ와 K가 $x = x'$에서 continuous이면 $f(x)$는 continuity in mean square at $x = x'$를 만족한다.

2.5 Continuity

Sample Path Continuity

- **Definition**: f is simultaneously continuous at every $x \in \mathcal{X}$ with probability one.
- Continuity in Mean Square를 만족한다고 해서 sample path continuity를 만족하는 것은 아니지만, 가정이 추가된다면 만족함.

Theorem (Sample Path Continuity)

Suppose $\mathcal{X} \subset \mathbb{R}^d$ is compact and $f : \mathcal{X} \to \mathbb{R}$ has Gaussian process distribution $\mathcal{GP}(f; \mu, K)$, where μ is continuous and K is Hölder continuous. Then f is almost surely continuous on $\mathcal{X}$.

보충설명

- Hölder continuous: 너무 급격하게 변하지 않는 연속.
  $|f(x) - f(y)| \leq C||x - y||^{\alpha}$

Q. Proof: Almost Sure Continuity of GP

Q. Proof

Theorem 증명 방법과 Non-Euclidean에서의 Theorem이 궁금합니다.

흐름: dudley's entropy thm을 만족함을 보이기

Theorem 1.3.5 함수의 진동폭에 상한이 있다(Adler, 2007)

Let f be a centered Gaussian field on a d-compact, d the canonical metric, and H the corresponding entropy. Then there exists a random variable $\eta \in (0, \infty)$ and a universal constant K such that

$$\omega_{f,d}(\delta) \leq K \int_0^\delta H^{1/2}(\epsilon)\, d\epsilon \tag{1}$$

for all $\delta < \eta$.

- $\omega_{f,d}(\delta) = \sup\{|f(x) - f(y)| : d(x, y) \leq \delta\}$
- $H(\epsilon)$: The **metric entropy** defined as $\log N(X, d, \epsilon)$.
- $H^{1/2}(\epsilon)$: Equivalent to $\sqrt{H(\epsilon)}$.

Q. Proof: Almost Sure Continuity of GP (1/3)

Step 1: Canonical Metric and Hölder Continuity

- Define the canonical metric $d_K(x, y) = \sqrt{\mathbb{E}|f(x) - f(y)|^2}$.
- Since K is Hölder continuous with exponent $\alpha \in (0, 1]$:

$$|K(x, y) - K(x', y')| \leq C(\|x - x'\|^\alpha + \|y - y'\|^\alpha)$$

- The distance d_K satisfies:

$$\begin{aligned} d_K^2(x, y) &= K(x, x) + K(y, y) - 2K(x, y) \\ &\leq |K(x, x) - K(x, y)| + |K(y, y) - K(y, x)| \leq 2C\|x - y\|^\alpha \end{aligned}$$

- Therefore, $d_K(x, y) \leq L\|x - y\|^{\alpha/2}$ for some constant L.

Proof: Almost Sure Continuity of GP (2/3)

Step 2: Metric Entropy $H(\epsilon)$

- Let $N(X, d, \epsilon)$ be the covering number. From $d_K(x, y) \leq L\|x - y\|^{\alpha/2}$, a d_K-ball of radius ϵ contains a Euclidean ball of radius $r = (\epsilon/L)^{2/\alpha}$.
- For compact $X \subset \mathbb{R}^d$, the Euclidean covering number is $N(X, \|\cdot\|, r) \leq (A/r)^d$.
- Substituting r:

$$N(X, d_K, \epsilon) \leq N(X, \|\cdot\|, (\epsilon/L)^{2/\alpha}) \leq C'\epsilon^{-2d/\alpha}$$

- The **Metric Entropy** $H(\epsilon) = \log N(X, d_K, \epsilon)$ is bounded by:

$$H(\epsilon) \leq \log(C'\epsilon^{-2d/\alpha}) = \text{const} + \frac{2d}{\alpha} \log\left(\frac{1}{\epsilon}\right)$$

Proof: Almost Sure Continuity of GP (3/3)

Step 3: Convergence of Dudley's Integral

- Apply **Theorem 1.3.5**: The continuity modulus $\omega_{f,d}(\delta)$ is bounded by:

$$\omega_{f,d}(\delta) \leq K \int_0^\delta \sqrt{H(\epsilon)}\, d\epsilon \leq K' \int_0^\delta \sqrt{\log(1/\epsilon)}\, d\epsilon$$

- As $\epsilon \to 0$, $\sqrt{\log(1/\epsilon)}$ is integrable. Specifically, let $t = \log(1/\epsilon)$, then the integral near 0 behaves as:

$$\int_0^\delta \sqrt{\log(1/\epsilon)}\, d\epsilon \to 0 \quad \text{as } \delta \to 0$$

Conclusion

Since the integral converges, $\lim_{\delta \to 0} \omega_{f,d}(\delta) = 0$ almost surely. This implies f is uniformly continuous on (X, d_K), and thus f is **almost surely continuous** on X.

Differentiability in Mean Square

- **Definition**

$$\lim_{x \to x'} \mathbb{E}\left[\left|\frac{f(x+he_i)-f(x')}{h} - \frac{\partial f}{\partial x_i}(x)\right|^2\right] = 0$$

- 만약 μ와 K가 잘 미분된다면,

$$p\left(\frac{\partial f}{\partial x_i}(x)\middle| x\right) = \mathcal{N}\left(\frac{\partial f}{\partial x_i}(x); \frac{\partial \mu}{\partial x_i}(x), \frac{\partial^2 K}{\partial x_i \partial x_i'}(x,x)\right)$$

- 이때 Differentiability in Mean Square의 정의를 만족하므로, μ와 K가 잘 미분된다면 f는 Differentiability in Mean Square at x라 할 수 있다.
- **의의**: f와 ∇f의 Joint GP도 구할 수 있다.

2.6 Differentiability

f와 ∇f의 Joint GP

$$p(f, \nabla f) = \mathcal{GP}\left(\begin{bmatrix} f \\ \nabla f \end{bmatrix}; \begin{bmatrix} \mu \\ \nabla \mu \end{bmatrix}, \begin{bmatrix} K & K\nabla^\top \\ \nabla K & \nabla K \nabla^\top \end{bmatrix}\right) \tag{2.28}$$

- $[\nabla K(x, x')]_i = \mathrm{cov}\left[\frac{\partial f}{\partial x_i}(x), f(x') \mid x, x'\right] = \frac{\partial K}{\partial x_i}(x, x')$
- $[\nabla K \nabla^\top(x, x')]_{ij} = \mathrm{cov}\left[\frac{\partial f}{\partial x_i}(x), \frac{\partial f}{\partial x_j'}(x') \middle| x, x'\right] = \frac{\partial^2 K}{\partial x_j \partial x_j'}(x, x')$

f를 관측해서 ∇f를 추론하거나, 그 반대도 가능함

- Continuous differentiability $\implies$ Sample path continuity of the gradient process
- 가까운 위치 x, x'에 대해 f를 관측하면 ∇f 추론의 불확실성 감소 (Fig 2.8)
- ∇f 관측값을 f 추론에 반영 가능

2.6 Differentiability: Conditioning on Derivative Observations

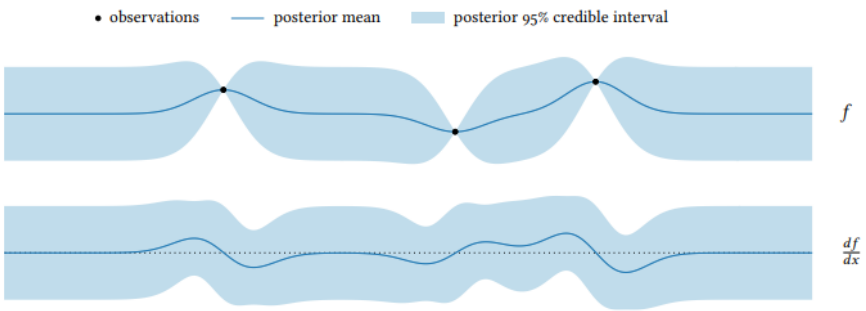

figure2.7

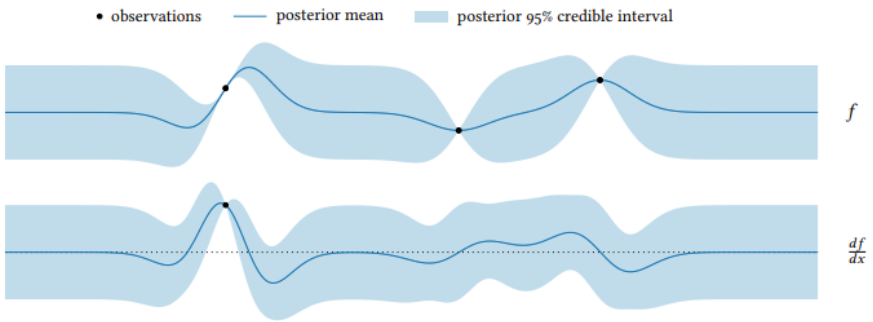

figure2.9

- f 관측값은 그대로이고 ∇f 관측값 한 개가 추가되었는데 그래프가 달라진 것을 볼 수 있음.

$(hf = \text{vech}\nabla\nabla^\top f)$ 라 할 때,

$$p(hf) = \mathcal{GP}(hf; h\mu, hKh^\top) \quad (2.29)$$

- 따라서 $f, \nabla f, hf$의 Joint GP를 구할 수 있다.
- **결론: GP는 미분에 관한 정보도 잘 나타낸다.**

2.6 Differentiability: Other Linear Transformations

- 미분은 Linear Operator이고, Gaussian distribution에 Linear transformation을 취해도 여전히 Gaussian.
- $p(f) = \mathcal{GP}(f; \mu, K)$이고 $Z = \int f(x)p(x)dx$라 하자.
- 이때, f와 Z 간의 Joint GP를 구할 수 있음.
- **활용**:
  - Z를 추론하거나 (= Bayesian Quadrature)
  - 반대로 Z에 대한 근사치(ex: Monte Carlo estimate) 정보로 f를 추론할 수도 있다.

Q. Cross Covariance의 직관적 의미

- **Q.** $f, \nabla f$, Hessian f의 Joint GP에서 Cross covariance term의 직관적 의미가 궁금합니다.
- **A.** $k(x, x') = \exp\left(-\frac{(x-x')^2}{2}\right)$라 두고 계산해봅시다.

1. f와 ∇f

- $\mathrm{Cov}(f, \nabla f) = (x - x') \cdot k(x, x')$
- **Case A:** $x = x'$ **(같은 지점)**
  - 값: **0**
  - 의미: 내가 산 정상(높음)에 있다고 해서, 지금 밟고 있는 땅의 기울기를 알 수는 없다. (높이와 기울기는 독립)
- **Case B:** $x \neq x'$ **(이웃 지점)**
  - $x' > x$ (오른쪽): **음수(-)**. 내가 높으면($f \uparrow$), 내 오른쪽은 **내리막 ($\nabla f < 0$)**이어야 한다.
  - $x' < x$ (왼쪽): **양수(+)**. 내가 높으면($f \uparrow$), 내 왼쪽은 **오르막($\nabla f > 0$)** 이어야 한다.

Q. Cross Covariance의 직관적 의미

2. f와 $\nabla^2 f$

- $\mathrm{Cov}(f, \nabla^2 f) = ((x - x')^2 - 1) \cdot k(x, x')$
- **Case A:** $x = x'$ **(같은 지점)**
  - 값: **-1**
  - 의미: **Peak vs Valley**
    - f가 높다 $\rightarrow$ 산봉우리 $\rightarrow$ 위로 볼록($\cap$) $\rightarrow$ $\nabla^2 f$**는 음수**
    - f가 낮다 $\rightarrow$ 골짜기 $\rightarrow$ 아래로 볼록($\cup$) $\rightarrow$ $\nabla^2 f$**는 양수**
- **Case B:** $x \neq x'$ **(이웃 지점)**
  - 거리에 따라 부호가 바뀜.
  - 내가 산봉우리라면, 일정 거리 떨어진 곳은 골짜기가 시작되어야 매끄럽게 연결됨.

Q. Cross Covariance의 직관적 의미

3. ∇f와 $\nabla^2 f$

- $\mathrm{Cov}(\nabla f, \nabla^2 f) = (x - x')(3 - (x - x')^2) \cdot k(x, x')$
- **Case A:** $x = x'$ **(같은 지점)**
  - 값: **0**
  - 의미: "지금 가파르다(∇f 큼)"는 사실만으로는 "여기가 휘어지는 구간($\nabla^2 f \neq 0$)인지 직선 구간인지" 알 수 없다.
- **Case B:** $x \neq x'$ **(이웃 지점)**
  - 값: **Non-zero**
  - 의미: 내 위치의 곡률($\nabla^2 f$)은 내 옆 지점(x')의 기울기(∇f)가 **앞으로 어떻게 변할지**를 예측해줌.
  - (예: 위로 볼록($\cap$)하면, 오른쪽으로 갈수록 기울기는 작아져야 함)

Q. bayesian quadrature

Q

bayesian quadrature가 어떻게 적분을 linear operation으로 근사하는지 궁금합니다.

A. Bayesian quadrature는 $Z = \int f(x)p(x)dx$를 추정하는 방법.
$p(Z|D)$를 구해서 $E(Z|D), Cov(Z|D)$ 등을 이용하면 됨.

$$\hat{Z} = \mathbb{E}[Z|D] = \mathbb{E}[\int f(x)p(x)dx|\mathcal{D}] = \int \mathbb{E}[f(x)|\mathcal{D}]p(x)dx$$

$$= \int (\mathbf{k}(x)^\top \mathbf{K}^{-1}\mathbf{y})p(x)dx = \underbrace{\left(\int \mathbf{k}(x)^\top p(x)dx\right)}_{\text{Kernel Mean}} \mathbf{K}^{-1}\mathbf{y}$$

A. 적분은 $\mathcal{L}[af(x) + bg(x)] = a\mathcal{L}[f(x)] + b\mathcal{L}[g(x)]$니까 선형 연산자

2.7 Existence and Uniqueness of Global Maxima

목표: 최종 목표(f를 최대화하는 지점 찾기)가 제대로 정의되는지 확인.

기호:

$$x^* = \arg\max_{x \in \mathcal{X}} f(x); \quad f^* = \max_{x \in \mathcal{X}} f(x) = f(x^*)$$

주요 이슈:

1. 임의의 Objective function f에 대해 f^*의 존재성을 보장할 수 있는가?
2. f^*가 유일한가?

- 유일하지 않다면 Set-valued Random Variable x에 대해 문제를 풀어야 해서 너무 복잡함.
- **결론**: 마일드한 가정 하에서 1, 2가 Almost Surely하게 성립함. 즉, 문제가 잘 정의됨.

2.7 Existence and Uniqueness of Global Maxima

Existence of Global Maxima

- f가 Continuous하고 Domain이 Compact하면 **Extreme Value Theorem**에 의해 자명하게 존재함.

2.7 Existence and Uniqueness of Global Maxima

f^*가 존재한다면, 유일하다.

Theorem (Kim and Pollard, 1990)

Let $\mathcal{X}$ be a compact metric space. Suppose $f : \mathcal{X} \to \mathbb{R}$ has distribution $\mathcal{GP}(f; \mu \equiv 0, K)$, and that f is sample path continuous.
If for all $x, x' \in \mathcal{X}$ with $x \neq x'$ we have

$$\mathrm{var}[\phi - \phi' | x, x'] = K(x, x) - 2K(x, x') + K(x', x') \neq 0$$

then f almost surely has a unique maximum on $\mathcal{X}$.

직관적 이해

- $\mathrm{Var}(f(x) - f(x'))$가 0이 아님 $\implies$ $f(x) - f(x')$는 정규분포를 따름.
- 연속형 확률변수가 특정 값(0)일 확률은 0임.
- 참고: Supremum의 유일성(Arcones(1992))은 Sample path continuity 없이 증명 가능.

2.7 Counterexamples

KIM and POLLARD의 Theorem의 두 가지 조건이 위배될 경우의 반례

1. Sample path continuity가 위배될 경우:

- **White Noise GP** ($\mu(x) \equiv 0$, $K(x, x') = [x = x']$)
- 모든 지점이 서로 독립이라 $f(x)$가 최대라고 가정해도 $f(x')$가 더 클 수 있음.

2. Variance 조건이 위배될 경우:

- **Periodic Parametric Model**: $f(x) = a\cos x + b\sin x$ on $[0, 4\pi]$.
- $f(x) = R\cos(x - \theta) \sim GP$
- $\mu(x) = 0$, $K(x, x') = \cos(x - x')$.
- 특징: f는 Sample path continuous 만족, Global maximum 존재 ($\because$ continuity of μ, Hölder continuity of K)
- 문제: f가 주기성을 가져서 Global maximum이 여러 개 존재함.
- 이유: $\mathrm{Var}(f(x) - f(x + 2\pi)) = 0$, 즉 Variance 조건 위배됨.

2.8 Non-Gaussian Observations and Constraints

- 태생적으로 Non-Gaussian인 관측치(ex: heavy tail noise가 있는 관측치)는 t-분포로 근사할 수는 있지만 정확하게 추론할 수는 없음.
- 또한 $f(x) > 0$ 등의 **제약조건**은 추론에 필요한 정보를 제공하지만, GP 공식에 이를 넣는 것이 어렵고 수학적으로 문제가 될 수도 있음.
  - 예: Local maximum이 있다고 가정하면 $f''(x) > 0 \implies$ GP가 아니게 됨.
- **해결책**: Factor graph

2.8 General Case

상황 설정: Non-Gaussian observation → 정보가 들어오면 Non Gaussian이 되는 Gaussian latent

- 구하고자 하는 것: posterior (즉, $p(f|D)$)
- f와 함께 Joint GP를 따르는 $\mathbf{y}$가 있다고 하자 (y: latent function, not obs)
- $\mathcal{D}$라는 정보가 들어오면 $\mathbf{y}|\mathcal{D}$가 Non-Gaussian이 됨.

$$p(\mathbf{y}|\mathcal{D}) \propto p(\mathbf{y})t(\mathbf{y}) = \mathcal{N}(\mathbf{y}; \mathbf{m}, C)t(\mathbf{y}) \quad (2.33)$$

Then, **Posterior on** f:

$$p(f|\mathcal{D}) = \int p(f|\mathbf{y})p(\mathbf{y}|\mathcal{D})d\mathbf{y} \quad (2.34)$$

- **문제점**: 적분이 어려움→Monte Carlo Sampling 혹은 gaussian approximate inference 사용

2.8 Monte Carlo Sampling

접근법: Monte Carlo Sampling

1. Posterior sample 추출: $\{\mathbf{y}_i\}_{i=1}^{S} \sim p(\mathbf{y}|\mathcal{D})$ (ESS 사용)';
2. Mixture of Gaussians로 근사:

$$p(f|\mathcal{D}) = \int p(f|y)p(y|D)dy \approx \frac{1}{S}\sum_{i=1}^{S} p(f|\mathbf{y}_i) = \frac{1}{S}\sum_{i=1}^{S} \mathcal{GP}(f; \mu_{\mathcal{D}_i}, K_{\mathcal{D}})$$

where $\mu_{D_i}(x) = \mu(x) + k(x)^T C^{-1}(y - m)$;
$K_D(x, x') = K(x, x') - k(x)^T C^{-1} k(x')$

결과 확인: 이상치를 잘 무시하고 Objective function을 잘 근사

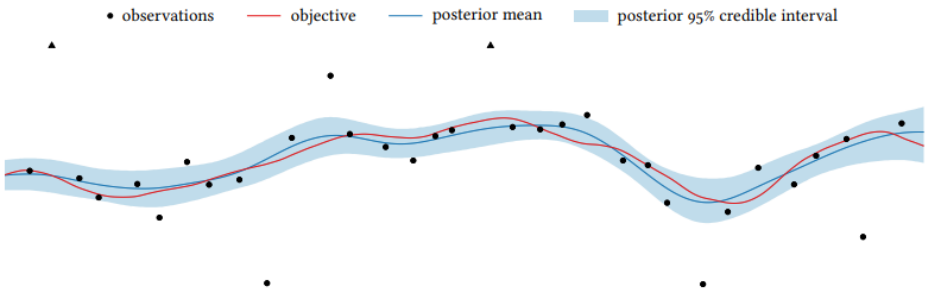

Figure: 2.12

타원 슬라이스 샘플링 (Elliptical Slice Sampling, ESS)

1. 핵심 개념: 가우시안 사전 분포에 특화된 샘플링

- **대상:** 가우시안 사전 분포($f \sim \mathcal{N}(0, \Sigma)$)를 가진 모델.
- **원리:** 현재 상태 f와 새로운 가우시안 샘플 $\nu \sim \mathcal{N}(0, \Sigma)$를 정의하고, 두 점을 잇는 **타원** 궤적 위에서 다음 지점을 탐색:

$$f^* = f \cos\theta + \nu \sin\theta, \quad \theta \in [0, 2\pi]$$

- 타원 위의 각도 θ에 대해 슬라이스 샘플링을 수행하여 새로운 상태를 결정함.

MH나 HMC 대비 ESS를 사용하는 이유

- **Tuning-Free (튜닝 불필요):** Metropolis-Hastings의 제안 분포 분산이나 HMC의 Step size처럼 성능에 직결되는 하이퍼파라미터를 설정할 필요가 없음.
- **고차원에서의 안정성:** 가우시안 프로세스(GP)와 같이 파라미터가 수천 차원 이상인 경우에도, 사전 분포의 구조를 그대로 활용하므로 매우 안정적으로 수렴함.
- **기울기 불필요:** HMC와 달리 가능도 함수의 기울기를 계산할 필요가 없어, 미분 불가능하거나 복잡한 모델에도 적용 가능함.

2.8 Gaussian approximate inference

아이디어: $p(y|D)$을 샘플링하지 말고, 가장 비슷한 GP로 근사하자

1. $p(\mathbf{y}|\mathcal{D}) \approx q(\mathbf{y}|\mathcal{D}) = \mathcal{N}(\mathbf{y}; \tilde{\mathbf{m}}, \tilde{C})$
2. 사용할 수 있는 근사 기법:
   - Laplace approximation
   - Gaussian expectation propagation (EP)
   - Variational Bayesian inference (VI)
3. $p(f|\mathcal{D}) \approx \int p(f|\mathbf{y})q(\mathbf{y}|\mathcal{D})d\mathbf{y} = \mathcal{GP}(f; \mu_{\mathcal{D}}, K_{\mathcal{D}})$

$\tilde{C}$의 특징

- 주로 $\tilde{C} = C - C(C+N)^{-1}C$ 형태
- 이는 additive gaussian noise를 갖는 y의 poseterior cov와 동일.
  $K_{\mathcal{D}}(x, x') = K(x, x') - \kappa(x)^\top (C+N)^{-1}\kappa(x') \quad (2.41)$
- 즉, additive Gaussian noise(Covariance=N)를 갖는 y의 posterior로 해석 가능

2.8 Gaussian approximate inference

예시) 다음의 정보를 반영해서 f의 posterior를 구하자.

1. $f'(x) = 0$
2. $f''(x) < 0$

절차:

- $f'(x) = 0$는 exact inference에 이용 가능(관측치로 취급)
- $h = f''(x)$라 하면, $p(h) = \mathcal{N}(h; m, s^2)$.
  h에 제약조건을 추가하면, $p(h|\mathcal{D}) \propto p(h)I(h < 0)$
  $\rightarrow$ Gaussian expectation propagation (EP)을 이용해서
  $p(h|D) \approx q(h|D) = N(h; \tilde{m}, \tilde{s}^2)$로 근사

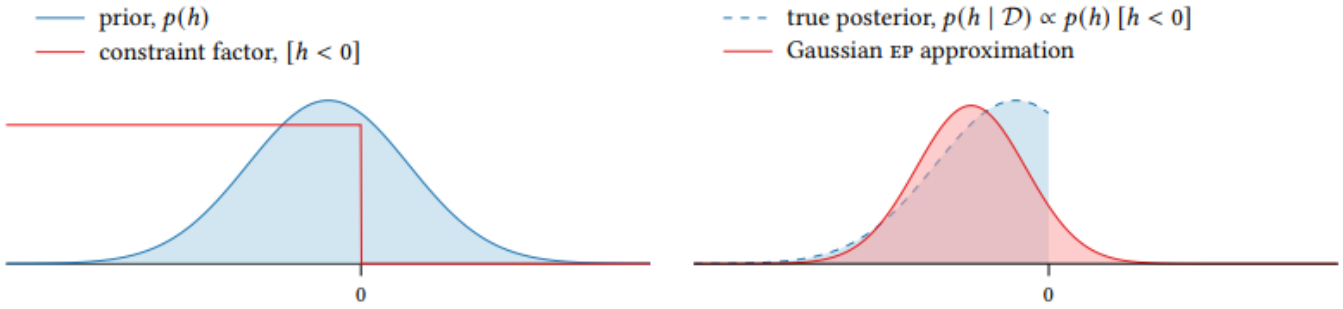

Figure: 2.14

2.8 Gaussian approximate inference

bayesian nonlinear regression으로 확장 가능.

- bayesian linear regression: y=wx+b에서 **w, b를 확률변수**로 보고 $p(w|data)$, $p(b|data)$를 구하는 것.
- bayesian nonlinear regression: $y = f(x) \sim GP$로 둠(목표: $p(f|data)$ 구하기)
- 2.8절에서 $p(f|D)$ 구하는 절차를 다룸 ($p(f, y)$ 설정 $\rightarrow$ $p(y|D)$ 설계 $\rightarrow$ $p(f|D)$)

Q

"This can be seen as a nonlinear extension of the well-known family of generalized linear models"라는 문장을 설명해주세요.

Q

Q

Laplace approximation, Gaussian EP, VB에 대해 간단한 소개와 함께 각 방법들의 장단점 및 언제 어떤 방법을 사용하면 좋을지 설명 부탁드립니다.

A.

구분	라플라스 근사	Gaussian EP	VB (VI)
핵심 특징	**최빈값** 중심의 local 근사	**모멘트** 중심의 global 근사	**최적화** 기반의 근사
정확도	최댓값 근처에서만 정확, 전체 질량 놓칠 수 있음	분포 전체 모양을 가장 잘 반영함	전반적으로 우수하나 분산 과소평가 가능성
계산 비용	가장 저렴하고 빠름	반복 계산으로 인해 비용이 높음	중간 (최적화 과정 필요)
추천 상황	단순한 모델, 빠른 계산이 최우선일 때	**베이지안 최적화** 등 정확한 불확실성이 핵심일 때	대규모 데이터, 복잡한 모델(Deep GP 등)

The Laplace Approximation

1. Define Log-Joint (Unnormalized Log-Posterior): Let $\Psi(x)$ be the logarithm of the unnormalized posterior:

$$\Psi(x) = \log p(x) + \log p(\mathcal{D}|x)$$

2. Find the Mode (MAP Estimate): Find the point $\hat{x}$ that maximizes $\Psi(x)$ (where gradient $\nabla\Psi(\hat{x}) = 0$):

$$\hat{x} = \arg\max_x \Psi(x)$$

3. Second-Order Taylor Expansion around $\hat{x}$: Since $\nabla\Psi(\hat{x}) = 0$, the expansion simplifies to:

$$\Psi(x) \approx \Psi(\hat{x}) - \frac{1}{2}(x - \hat{x})^\top H(x - \hat{x})$$

where $H = -\nabla^2\Psi(\hat{x})$ is the Hessian of the negative log posterior.

Result: Gaussian Approximation

$p(x|\mathcal{D}) \approx q(x) = \mathcal{N}(x; \hat{x}, H^{-1})$

- **Mean:** Mode of the posterior ($\hat{x}$).
- **Covariance:** Inverse curvature at the mode (H^{-1}).

Gaussian Expectation Propagation

Objective: Approximate posterior $p(y|\mathcal{D})$ where factors $t_i(y_i)$ are non-Gaussian:

$$p(y|\mathcal{D}) \propto p(y) \prod_i t_i(y_i) \quad \xrightarrow{\text{Approx}} \quad q(y|\mathcal{D}) \propto p(y) \prod_i \tilde{t}_i(y_i)$$

Here, $\tilde{t}_i(y_i)$ are unnormalized Gaussian approximations to the factors.
Key Idea: Minimize $D_{KL}(p||q)$ via **Moment Matching** on y.

Iterative Update for Factor $t_i(y_i)$

1. **Cavity Step:** Remove current approximation $\tilde{t}_i$ from the posterior $q(y|\mathcal{D})$.

$$q^{\setminus i}(y) \propto \frac{q(y|\mathcal{D})}{\tilde{t}_i(y_i)}$$

2. **Tilted Distribution:** Insert the *true* factor $t_i(y_i)$ (e.g., constraint).

$$\hat{p}(y) \propto q^{\setminus i}(y) t_i(y_i)$$

3. **Moment Matching:** Update $\tilde{t}_i$ so that $q(y|\mathcal{D})$ matches the mean and covariance of the tilted distribution $\hat{p}(y)$.

Variational Bayesian Inference (Notation from §2.8)

1. Objective Function (Reverse KL)

Minimize the divergence between the approximation q and true posterior p:

$$\min_q D_{KL}(q(y)||p(y|\mathcal{D}))$$

2. Evidence Lower Bound (ELBO)

Since $p(y|\mathcal{D})$ is intractable, we maximize the **ELBO** instead:

$$\log p(\mathcal{D}) = \underbrace{\text{ELBO}(q)}_{\text{Maximize}} + \underbrace{D_{KL}(q||p)}_{\text{Minimize}}$$

$$\text{ELBO}(q) = \mathbb{E}_q[\log p(y)t(y)] - \mathbb{E}_q[\log q(y)]$$

Procedure: Find parameters of $q(y)$ (e.g., μ, Σ) that maximize the ELBO using Gradient Ascent (Machine Learning approach).

Q

Q

2.8에서 기존 additive Gaussian noise model에서 noise로 Normal이 아니라 Student-t 에러 모형을 사용하는 예시를 보여주는데, 실제 현실에서는 언제 Normal, Student-t를 사용하는지 결정하는 방법이 있을까요? 단순 outlier가 많으면 heavy tail 모형을 고려하는걸로 생각하면 될까요?

A. 모델이 직접 정하게 하기. t분포로 우선 모델링하고, 자유도가 작으면 t분포, 아니면 정규분포 쓰기(4 근처면 보통 작다고 함)
A. LOO-CV나 WAIC등을 써서 정규분포, t분포 모델을 비교해서 결정.
A. 데이터에 이상치가 포함되어있다고 확신하는 경우에 t분포를 쓰기. (이상치를 노이즈로 간주하고 무시하고 싶을 때 t 분포.)